

Фильтр Кальмана

Теория Управления, лекция 11

Сергей Савин

2026

ВНУТРЕННЕЕ И ВНЕШНЕЕ ПРОИЗВЕДЕНИЯ

Внутреннее произведение $\mathbf{x}^\top \mathbf{x}$ и внешнее произведение $\mathbf{x}\mathbf{x}^\top$ определяются как:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

$$\mathbf{x}^\top \mathbf{x} = x_1^2 + x_2^2 + x_3^2,$$

$$\mathbf{x}\mathbf{x}^\top = \begin{bmatrix} x_1^2 & x_1x_2 & x_1x_3 \\ x_2x_1 & x_2^2 & x_2x_3 \\ x_3x_1 & x_3x_2 & x_3^2 \end{bmatrix}$$

СЛУЧАЙНАЯ ВЕЛИЧИНА, 1

Случайная величина $\mathbf{v}$ принимает значения в соответствии с распределением вероятностей. Мы можем наблюдать реализации $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3, \dots$ взятые из этого распределения.

Среднее $\bar{\mathbf{v}}$ случайной величины $\mathbf{v}$ обозначается как:

$$\bar{\mathbf{v}} = E[\mathbf{v}] \quad (1)$$

Среднее обладает рядом свойств:

$$E[\mathbf{a}] = \mathbf{a}, \quad \mathbf{a} = \text{const} \quad (2)$$

$$E[\mathbf{x} + \mathbf{y}] = E[\mathbf{x}] + E[\mathbf{y}] \quad (3)$$

$$E[\alpha \mathbf{x}] = \alpha E[\mathbf{x}] \quad \alpha = \text{const} \in \mathbb{R} \quad (4)$$

$$E[\mathbf{A} \mathbf{x}] = \mathbf{A} E[\mathbf{x}] \quad \mathbf{A} = \text{const} \quad (5)$$

СЛУЧАЙНАЯ ВЕЛИЧИНА, 2

Автоковариация $\mathbf{V} = \mathbf{cov}(\mathbf{v}, \mathbf{v})$ случайной величины $\mathbf{v}$ определяется как:

$$\mathbf{cov}(\mathbf{v}, \mathbf{v}) = E[(\mathbf{v} - E[\mathbf{v}])(\mathbf{v} - E[\mathbf{v}])^\top] \quad (6)$$

Для упрощения записи в следующих разделах определим $\mathbf{cov}(\mathbf{v}) = \mathbf{cov}(\mathbf{v}, \mathbf{v})$. Для процесса с нулевым средним $E[\mathbf{v}] = 0$ формула упрощается:

$$\mathbf{cov}(\mathbf{v}) = E[\mathbf{v}\mathbf{v}^\top] \quad (7)$$

Автоковариация обладает рядом свойств:

$$\mathbf{cov}(\mathbf{a}) = \mathbf{0}, \quad \mathbf{a} = \text{const} \quad (8)$$

$$\mathbf{cov}(\mathbf{x} + \mathbf{a}) = \mathbf{cov}(\mathbf{x}), \quad \mathbf{a} = \text{const} \quad (9)$$

$$\mathbf{cov}(\alpha \mathbf{x}) = \alpha^2 \mathbf{cov}(\mathbf{x}) \quad (10)$$

Случайная величина $\mathbf{x}$ с гауссовским распределением может быть полностью описана своим средним $\bar{\mathbf{x}}$ и ковариацией $\mathbf{X}$:

$$\mathbf{x} \sim \mathcal{N}(\bar{\mathbf{x}}, \mathbf{X}) \quad (11)$$

СРЕДНЕЕ ЛИНЕЙНОГО ПРЕОБРАЗОВАНИЯ

Пусть $\mathbf{x}$ — случайная величина $\mathbf{x} \sim \mathcal{N}(\bar{\mathbf{x}}, \mathbf{X})$. Для постоянной матрицы $\mathbf{M}$ можно определить линейное преобразование $\mathbf{y}$:

$$\mathbf{y} = \mathbf{M}\mathbf{x} \quad (12)$$

Найдём среднее $\mathbf{y}$:

$$E[\mathbf{y}] = E[\mathbf{M}\mathbf{x}] \quad (13)$$

$$E[\mathbf{y}] = \mathbf{M}E[\mathbf{x}] \quad (14)$$

$$E[\mathbf{y}] = \mathbf{M}\bar{\mathbf{x}} \quad (15)$$

Если $\bar{\mathbf{x}} = E[\mathbf{x}] = 0$, то $\bar{\mathbf{y}} = E[\mathbf{y}] = 0$.

АВТОКОВАРИАЦИЯ ПРИ ЛИНЕЙНОМ ПРЕОБРАЗОВАНИИ

Полагая $\bar{\mathbf{x}} = E[\mathbf{x}] = 0$, получаем $E[\mathbf{y}] = 0$; тогда можно найти автоковариацию $\mathbf{y}$:

$$\begin{aligned}\mathbf{cov}(\mathbf{y}) &= E[(\mathbf{y} - E[\mathbf{y}])(\mathbf{y} - E[\mathbf{y}])^\top] = \\ &= E[\mathbf{y}\mathbf{y}^\top] = \\ &= E[(\mathbf{M}\mathbf{x})(\mathbf{M}\mathbf{x})^\top] = \\ &= E[\mathbf{M}\mathbf{x}\mathbf{x}^\top\mathbf{M}^\top] = \\ &= \mathbf{M}E[\mathbf{x}\mathbf{x}^\top]\mathbf{M}^\top = \\ &= \mathbf{M}\mathbf{X}\mathbf{M}^\top\end{aligned}$$

Предположим, что ДТ-ЛПП динамика имеет вид:

$$\mathbf{x}_{i+1} = \mathbf{A}\mathbf{x}_i + \mathbf{B}\mathbf{u}_i + \mathbf{w}_i, \quad (16)$$

где $\mathbf{w} \sim \mathcal{N}(0, \mathbf{Q})$ — шум процесса — случайный вход с гауссовским распределением, и $\mathbf{Q} \succeq 0$ (то есть положительно полуопределена). Предложим наблюдатель разомкнутого контура:

$$\hat{\mathbf{x}}_{i+1} = \mathbf{A}\hat{\mathbf{x}}_i + \mathbf{B}\mathbf{u}_i, \quad (17)$$

где $\hat{\mathbf{x}}$ — оценка состояния. Найдём динамику ошибки оценивания $\tilde{\mathbf{x}} = \mathbf{x}_i - \hat{\mathbf{x}}_i$:

$$\tilde{\mathbf{x}}_{i+1} = \mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i \quad (18)$$

Предположим, что можно выбрать начальную оценку состояния $\hat{\mathbf{x}}_0$ так, чтобы начальная ошибка оценивания $\tilde{\mathbf{x}}_0$ вела себя как случайная величина, взятая из гауссовского распределения $\tilde{\mathbf{x}}_0 \sim \mathcal{N}(0, \mathbf{P}_0)$.

Зная среднее $E[\tilde{\mathbf{x}}_i]$, можно вычислить $E[\tilde{\mathbf{x}}_{i+1}]$:

$$E[\tilde{\mathbf{x}}_{i+1}] = E[\mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i] = \mathbf{A}E[\tilde{\mathbf{x}}_i] \quad (19)$$

Поскольку $E[\tilde{\mathbf{x}}_0] = 0$, можно заключить, что $E[\tilde{\mathbf{x}}_i] = 0, \forall i$.

ОШИБКА ОЦЕНИВАНИЯ СОСТОЯНИЯ — КОВАРИАЦИЯ

Зная автоковариацию $\mathbf{P}_i$, можно вычислить $\mathbf{P}_{i+1}$:

$$\begin{aligned}\mathbf{P}_{i+1} &= E[\tilde{\mathbf{x}}_{i+1}\tilde{\mathbf{x}}_{i+1}^\top] = E[(\mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i)(\mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i)^\top] = \\ &= E[\mathbf{A}\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top \mathbf{A}^\top + \mathbf{A}\tilde{\mathbf{x}}_i\mathbf{w}_i^\top + \mathbf{w}_i\tilde{\mathbf{x}}_i^\top \mathbf{A}^\top + \mathbf{w}_i\mathbf{w}_i^\top]\end{aligned}$$

Предположим, что $\mathbf{w}$ не зависит от состояния (и ошибки оценивания), то есть $E[\tilde{\mathbf{x}}_i\mathbf{w}_i^\top] = E[\mathbf{w}_i\tilde{\mathbf{x}}_i^\top] = 0$:

$$\mathbf{P}_{i+1} = E[\mathbf{A}\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top \mathbf{A}^\top + \mathbf{w}_i\mathbf{w}_i^\top] = \mathbf{A}\mathbf{P}_i\mathbf{A}^\top + \mathbf{Q}$$

Ранее мы вычислили динамику среднего и ковариации ошибки оценивания состояния для случая наблюдателя разомкнутого контура. Однако устойчивый наблюдатель с обратной связью, очевидно, предпочтительнее. Начнём с введения модели измерений:

$$\mathbf{y}_i = \mathbf{H}\mathbf{x}_i + \mathbf{v}_i \quad (20)$$

где $\mathbf{H}$ — матрица измерений, $\mathbf{y}_i$ — измеренный выход, а $\mathbf{v}_i$ — шум измерений, взятый из гауссовского распределения $\mathbf{v}_i \sim \mathcal{N}(0, \mathbf{R})$, где $\mathbf{R} \succ 0$.

Предложим следующую модификацию наблюдателя:

$$\begin{cases} \hat{\mathbf{x}}_{i+1}^- = \mathbf{A}\hat{\mathbf{x}}_i + \mathbf{B}\mathbf{u}_i, \\ \hat{\mathbf{x}}_{i+1} = \hat{\mathbf{x}}_{i+1}^- + \mathbf{L}_i(\mathbf{y}_i - \mathbf{H}\hat{\mathbf{x}}_{i+1}^-) \end{cases} \quad (21)$$

где $\hat{\mathbf{x}}_{i+1}^-$ — априорная оценка. Последнее уравнение можно переписать как $\hat{\mathbf{x}}_{i+1} = \hat{\mathbf{x}}_{i+1}^- + \mathbf{L}_i(\mathbf{H}\mathbf{x}_i - \mathbf{H}\hat{\mathbf{x}}_{i+1}^- + \mathbf{v}_i)$.

Перепишем всё в терминах ошибки оценивания состояния, определив $\tilde{\mathbf{x}}_{i+1}^- = \mathbf{x}_{i+1} - \hat{\mathbf{x}}_{i+1}^-$. Для последнего уравнения в (21) вычтем $\mathbf{x}_{i+1}$ из обеих частей:

$$\hat{\mathbf{x}}_{i+1} - \mathbf{x}_{i+1} = \hat{\mathbf{x}}_{i+1}^- - \mathbf{x}_{i+1} + \mathbf{L}_i(\mathbf{H}\mathbf{x}_i - \mathbf{H}\hat{\mathbf{x}}_{i+1}^- + \mathbf{v}_i) \quad (22)$$

и изменим знак:

$$\begin{cases} \tilde{\mathbf{x}}_{i+1}^- = \mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i, \\ \tilde{\mathbf{x}}_{i+1} = (\mathbf{I} - \mathbf{L}_i\mathbf{H})\tilde{\mathbf{x}}_{i+1}^- + \mathbf{L}_i\mathbf{v}_i \end{cases} \quad (23)$$

НАБЛЮДАТЕЛЬ С ОБРАТНОЙ СВЯЗЬЮ — ДИНАМИКА СРЕДНЕГО

Вычислим динамику среднего ошибки оценивания
(распространение):

$$E[\tilde{\mathbf{x}}_{i+1}^-] = E[\mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i] = E[\mathbf{A}\tilde{\mathbf{x}}_i] + E[\mathbf{w}_i] = \mathbf{A}E[\tilde{\mathbf{x}}_i].$$

$$\begin{aligned} E[\tilde{\mathbf{x}}_{i+1}] &= E[(\mathbf{I} - \mathbf{L}_i\mathbf{H})\tilde{\mathbf{x}}_{i+1}^- + \mathbf{L}_i\mathbf{v}_i] = \\ &= E[(\mathbf{I} - \mathbf{L}_i\mathbf{H})\tilde{\mathbf{x}}_{i+1}^-] = (\mathbf{I} - \mathbf{L}_i\mathbf{H})E[\tilde{\mathbf{x}}_{i+1}^-] \end{aligned}$$

Итак, получаем следующую динамику среднего:

$$\begin{cases} E[\tilde{\mathbf{x}}_{i+1}^-] = \mathbf{A}E[\tilde{\mathbf{x}}_i], \\ E[\tilde{\mathbf{x}}_{i+1}] = (\mathbf{I} - \mathbf{L}_i\mathbf{H})E[\tilde{\mathbf{x}}_{i+1}^-] \end{cases} \quad (24)$$

Поскольку $E[\tilde{\mathbf{x}}_0] = 0$, то $E[\tilde{\mathbf{x}}_1^-] = 0$, и тогда $E[\tilde{\mathbf{x}}_1] = 0$, и то же самое для $E[\tilde{\mathbf{x}}_i] = 0$, $E[\tilde{\mathbf{x}}_i^-] = 0$.

НАБЛЮДАТЕЛЬ С ОБРАТНОЙ СВЯЗЬЮ — ДИНАМИКА КОВАРИАЦИИ

Вычислим динамику автоковариации (распространение).

Ниже приведена ковариация *априорной* ошибки оценивания:

$$\begin{aligned}\mathbf{P}_{i+1}^- &= E[\tilde{\mathbf{x}}_{i+1}^- (\tilde{\mathbf{x}}_{i+1}^-)^\top] = \\ &= E[(\mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i)(\mathbf{A}\tilde{\mathbf{x}}_i + \mathbf{w}_i)^\top] = \\ &= E[\mathbf{A}\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top \mathbf{A}^\top + \mathbf{A}\tilde{\mathbf{x}}_i\mathbf{w}_i^\top + \mathbf{w}_i\tilde{\mathbf{x}}_i^\top \mathbf{A}^\top + \mathbf{w}_i\mathbf{w}_i^\top] = \\ &= \mathbf{A}\mathbf{P}_i\mathbf{A}^\top + \mathbf{Q}.\end{aligned}$$

Напоминание: $E[\mathbf{w}_i\mathbf{w}_i^\top] = \mathbf{Q}$, поскольку $\mathbf{w} \sim \mathcal{N}(0, \mathbf{Q})$,
 $E[\tilde{\mathbf{x}}_i\mathbf{w}_i^\top] = 0$, так как переменные независимы, и
 $E[\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top] = \mathbf{P}_i$ по определению.

НАБЛЮДАТЕЛЬ С ОБРАТНОЙ СВЯЗЬЮ — ДИНАМИКА КОВАРИАЦИИ

После этого найдём ковариацию *апостериорной* ошибки оценивания:

$$E[\tilde{\mathbf{x}}_{i+1}\tilde{\mathbf{x}}_{i+1}^\top] = E[(\mathbf{I} - \mathbf{L}_i\mathbf{H})\tilde{\mathbf{x}}_{i+1}^-(\tilde{\mathbf{x}}_{i+1}^-)^\top(\mathbf{I} - \mathbf{L}_i\mathbf{H})^\top + (\mathbf{I} - \mathbf{L}_i\mathbf{H})\tilde{\mathbf{x}}_{i+1}^-\mathbf{v}_i^\top + \mathbf{v}_i(\tilde{\mathbf{x}}_{i+1}^-)^\top(\mathbf{I} - \mathbf{L}_i\mathbf{H})^\top + \mathbf{L}_i\mathbf{v}_i\mathbf{v}_i^\top\mathbf{L}_i^\top]$$

Предполагая, что $\tilde{\mathbf{x}}_{i+1}^-$ и $\mathbf{v}_i$ некоррелированы, получаем $E[(\mathbf{I} - \mathbf{L}_i\mathbf{H})\tilde{\mathbf{x}}_{i+1}^-\mathbf{v}_i^\top] = 0$ и $E[\mathbf{v}_i(\tilde{\mathbf{x}}_{i+1}^-)^\top(\mathbf{I} - \mathbf{L}_i\mathbf{H})^\top] = 0$.

Упрощаем:

$$E[\tilde{\mathbf{x}}_{i+1}\tilde{\mathbf{x}}_{i+1}^\top] = (\mathbf{I} - \mathbf{L}_i\mathbf{H})\mathbf{P}_{i+1}^-(\mathbf{I} - \mathbf{L}_i\mathbf{H})^\top + \mathbf{L}_i\mathbf{R}\mathbf{L}_i^\top = \mathbf{P}_{i+1}$$

Коэффициент усиления фильтра Калмана

ПРЕДВАРИТЕЛЬНЫЕ СВЕДЕНИЯ, 1

Прежде чем обсуждать, как можно предложить коэффициент усиления Калмана, нам потребуются два математических факта. Во-первых, след внешнего произведения есть внутреннее произведение:

$$\mathbf{x}^\top \mathbf{x} = \text{tr}(\mathbf{x}\mathbf{x}^\top) \quad (25)$$

где $\text{tr}(\cdot)$ — операция взятия следа.

Пример:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, \quad \mathbf{x}^\top \mathbf{x} = x_1^2 + x_2^2 + x_3^2,$$
$$\mathbf{x}\mathbf{x}^\top = \begin{bmatrix} x_1^2 & x_1x_2 & x_1x_3 \\ x_2x_1 & x_2^2 & x_2x_3 \\ x_3x_1 & x_3x_2 & x_3^2 \end{bmatrix}, \quad \text{tr}(\mathbf{x}\mathbf{x}^\top) = x_1^2 + x_2^2 + x_3^2.$$

Во-вторых, производные следа:

$$\frac{\partial(\text{tr}(\mathbf{A}\mathbf{X}))}{\partial\mathbf{X}} = \frac{\partial(\text{tr}(\mathbf{X}\mathbf{A}))}{\partial\mathbf{X}} = \mathbf{A} \quad (26)$$

$$\frac{\partial(\text{tr}(\mathbf{A}\mathbf{X}^\top))}{\partial\mathbf{X}} = \frac{\partial(\text{tr}(\mathbf{X}^\top\mathbf{A}))}{\partial\mathbf{X}} = \mathbf{A}^\top \quad (27)$$

$$\frac{\partial(\text{tr}(\mathbf{A}\mathbf{X}))}{\partial\mathbf{X}^\top} = \frac{\partial(\text{tr}(\mathbf{X}\mathbf{A}))}{\partial\mathbf{X}^\top} = \mathbf{A}^\top \quad (28)$$

$$\frac{\partial(\text{tr}(\mathbf{X}^\top\mathbf{A}\mathbf{X}))}{\partial\mathbf{X}} = \mathbf{X}^\top(\mathbf{A} + \mathbf{A}^\top) \quad (29)$$

$$\frac{\partial(\text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^\top))}{\partial\mathbf{X}} = (\mathbf{A} + \mathbf{A}^\top)\mathbf{X}^\top \quad (30)$$

$$\frac{\partial(\text{tr}(\mathbf{X}^\top\mathbf{A}\mathbf{X}))}{\partial\mathbf{X}^\top} = (\mathbf{A} + \mathbf{A}^\top)\mathbf{X} \quad (31)$$

$$\frac{\partial(\text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^\top))}{\partial\mathbf{X}^\top} = \mathbf{X}(\mathbf{A} + \mathbf{A}^\top) \quad (32)$$

КОЭФФИЦИЕНТ УСИЛЕНИЯ КАЛМАНА, 1

Здесь мы попытаемся вывести оптимальный коэффициент усиления Калмана $\mathbf{L}_i$ для i -го шага, минимизирующий следующую функцию стоимости:

$$J = E \left[\sum \tilde{x}_{i+1}^2 \right] \quad (33)$$

то есть мы минимизируем среднее значение квадрата ошибки оценивания. Также мы знаем, что пока ошибка оценивания на $(i + 1)$ -м шаге имеет нулевое среднее (как случайная величина), ковариация имеет вид:

$\mathbf{P}_{i+1} = E[\tilde{\mathbf{x}}_{i+1}\tilde{\mathbf{x}}_{i+1}^\top]$. Её след даёт функцию стоимости J :

$$\begin{aligned} J &= E \left[\text{tr}(\tilde{\mathbf{x}}_{i+1}\tilde{\mathbf{x}}_{i+1}^\top) \right] = \text{tr}(E \left[\tilde{\mathbf{x}}_{i+1}\tilde{\mathbf{x}}_{i+1}^\top \right]) = \text{tr}(\mathbf{P}_{i+1}) = \\ &= \text{tr}((\mathbf{I} - \mathbf{L}_i\mathbf{H})\mathbf{P}_{i+1}^-(\mathbf{I} - \mathbf{L}_i\mathbf{H})^\top + \mathbf{L}_i\mathbf{R}\mathbf{L}_i^\top) = \\ &\text{tr}(\mathbf{P}_{i+1}^- - \mathbf{L}_i\mathbf{H}\mathbf{P}_{i+1}^- - \mathbf{P}_{i+1}^-\mathbf{H}^\top\mathbf{L}_i^\top + \mathbf{L}_i(\mathbf{H}\mathbf{P}_{i+1}^-\mathbf{H}^\top + \mathbf{R})\mathbf{L}_i^\top) \end{aligned}$$

КОЭФФИЦИЕНТ УСИЛЕНИЯ КАЛМАНА, 2

Далее найдём производную J по $\mathbf{L}_i$ и приравняем её к нулю:

$$\frac{\partial J}{\partial \mathbf{L}_i} = -\mathbf{H}\mathbf{P}_{i+1}^- - (\mathbf{P}_{i+1}^- \mathbf{H}^\top)^\top + 2(\mathbf{H}\mathbf{P}_{i+1}^- \mathbf{H}^\top + \mathbf{R})\mathbf{L}_i^\top = 0$$

$$-2\mathbf{H}\mathbf{P}_{i+1}^- + 2(\mathbf{H}\mathbf{P}_{i+1}^- \mathbf{H}^\top + \mathbf{R})\mathbf{L}_i^\top = 0$$

$$\mathbf{L}_i(\mathbf{H}\mathbf{P}_{i+1}^- \mathbf{H}^\top + \mathbf{R}) = \mathbf{P}_{i+1}^- \mathbf{H}^\top$$

$$\mathbf{L}_i = \mathbf{P}_{i+1}^- \mathbf{H}^\top (\mathbf{H}\mathbf{P}_{i+1}^- \mathbf{H}^\top + \mathbf{R})^{-1}$$

Итак, коэффициент усиления Калмана может быть оптимально выбран как $\mathbf{L}_i = \mathbf{P}_{i+1}^- \mathbf{H}^\top (\mathbf{H}\mathbf{P}_{i+1}^- \mathbf{H}^\top + \mathbf{R})^{-1}$.

Существуют альтернативные, но эквивалентные способы выбора $\mathbf{L}_i$. Можно сделать это «тем же способом», что и в LQR:

$$\mathbf{L}_i = \mathbf{P}_{i+1} \mathbf{H}^\top \mathbf{R}^{-1} \quad (34)$$

Эквивалентность этой формулы предыдущей будет показана в Приложении В.

- Simon, D., 2006. Optimal state estimation: Kalman, H infinity, and nonlinear approaches. John Wiley & Sons.

Слайды доступны на Github:

github.com/SergeiSa/Control-Theory-2026



Appendix A

MEAN OF AN AFFINE TRANSFORM

Given a constant vector $\mathbf{c}$ and a constant matrix $\mathbf{M}$ we can define an affine transformation of $\mathbf{x}$:

$$\mathbf{y} = \mathbf{M}\mathbf{x} + \mathbf{c} \quad (35)$$

We can find mean of $\mathbf{y}$:

$$E[\mathbf{y}] = E[\mathbf{M}\mathbf{x} + \mathbf{c}] \quad (36)$$

$$E[\mathbf{y}] = \mathbf{M}E[\mathbf{x}] + \mathbf{c} \quad (37)$$

$$E[\mathbf{y}] = \mathbf{M}\bar{\mathbf{x}} + \mathbf{c} \quad (38)$$

AUTO-COVARIANCE WITH ZERO MEAN

Assuming $E[\mathbf{x}] = 0$, we can find covariance of $\mathbf{y}$:

$$\begin{aligned}\mathbf{cov}(\mathbf{y}) &= E[(\mathbf{y} - E[\mathbf{y}])(\mathbf{y} - E[\mathbf{y}])^\top] = \\&= E[\mathbf{y}\mathbf{y}^\top + E[\mathbf{y}]E[\mathbf{y}]^\top - \mathbf{y}E[\mathbf{y}]^\top - E[\mathbf{y}]\mathbf{y}^\top] = \\&= E[\mathbf{y}\mathbf{y}^\top + \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - \mathbf{y}\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}\mathbf{y}^\top] = \\&= E[\mathbf{y}\mathbf{y}^\top] + \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - E[\mathbf{y}]\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}E[\mathbf{y}]^\top = \\&= E[\mathbf{y}\mathbf{y}^\top] + \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}\bar{\mathbf{y}}^\top = \\&= E[(\mathbf{M}\mathbf{x} + \mathbf{c})(\mathbf{M}\mathbf{x} + \mathbf{c})^\top] - \mathbf{c}\mathbf{c}^\top \\&= E[\mathbf{M}\mathbf{x}\mathbf{x}^\top\mathbf{M}^\top + \mathbf{c}\mathbf{c}^\top + \mathbf{M}\mathbf{x}\mathbf{c}^\top + \mathbf{c}\mathbf{x}^\top\mathbf{M}^\top] - \mathbf{c}\mathbf{c}^\top = \\&= \mathbf{M}\mathbf{X}\mathbf{M}^\top + \mathbf{M}\bar{\mathbf{x}}\mathbf{c}^\top + \mathbf{c}\bar{\mathbf{x}}^\top\mathbf{M}^\top = \\&= \mathbf{M}\mathbf{X}\mathbf{M}^\top\end{aligned}$$

AUTO-COVARIANCE OVER AFFINE TRANSFORM

Without this assumption, the covariance of $\mathbf{y}$ is a little more complicated:

$$\begin{aligned}\text{cov}(\mathbf{y}) &= E[(\mathbf{y} - E[\mathbf{y}])(\mathbf{y} - E[\mathbf{y}])^\top] = \\&= E[\mathbf{y}\mathbf{y}^\top + E[\mathbf{y}]E[\mathbf{y}]^\top - \mathbf{y}E[\mathbf{y}]^\top - E[\mathbf{y}]\mathbf{y}^\top] = \\&= E[\mathbf{y}\mathbf{y}^\top + \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - \mathbf{y}\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}\mathbf{y}^\top] = \\&= E[\mathbf{y}\mathbf{y}^\top] + \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - E[\mathbf{y}]\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}E[\mathbf{y}]^\top = \\&= E[\mathbf{y}\mathbf{y}^\top] + \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}\bar{\mathbf{y}}^\top - \bar{\mathbf{y}}\bar{\mathbf{y}}^\top \\&= E[(\mathbf{M}\mathbf{x} + \mathbf{c})(\mathbf{M}\mathbf{x} + \mathbf{c})^\top] - (\mathbf{M}\bar{\mathbf{x}} + \mathbf{c})(\mathbf{M}\bar{\mathbf{x}} + \mathbf{c})^\top \\&= E[\mathbf{M}\mathbf{x}\mathbf{x}^\top\mathbf{M}^\top + \mathbf{c}\mathbf{c}^\top + \mathbf{M}\mathbf{x}\mathbf{c}^\top + \mathbf{c}\mathbf{x}^\top\mathbf{M}^\top] - \\&\quad - (\mathbf{M}\bar{\mathbf{x}}\bar{\mathbf{x}}^\top\mathbf{M}^\top + \mathbf{M}\bar{\mathbf{x}}\mathbf{c}^\top + \mathbf{c}\bar{\mathbf{x}}^\top\mathbf{M}^\top + \mathbf{c}\mathbf{c}^\top) = \\&= \mathbf{M}\mathbf{X}\mathbf{M}^\top + \mathbf{c}\mathbf{c}^\top + \mathbf{M}\bar{\mathbf{x}}\mathbf{c}^\top + \mathbf{c}\bar{\mathbf{x}}^\top\mathbf{M}^\top - \\&\quad - (\mathbf{M}\bar{\mathbf{x}}\bar{\mathbf{x}}^\top\mathbf{M}^\top + \mathbf{M}\bar{\mathbf{x}}\mathbf{c}^\top + \mathbf{c}\bar{\mathbf{x}}^\top\mathbf{M}^\top + \mathbf{c}\mathbf{c}^\top) = \\&= \mathbf{M}\mathbf{X}\mathbf{M}^\top - \mathbf{M}\bar{\mathbf{x}}\bar{\mathbf{x}}^\top\mathbf{M}^\top\end{aligned}$$

Appendix B

Given observer gain $\mathbf{L}_i = \mathbf{P}_{i+1} \mathbf{H}^\top \mathbf{R}^{-1}$ and autocovariance propagation $\mathbf{P}_{i+1} = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- (\mathbf{I} - \mathbf{L}_i \mathbf{H})^\top + \mathbf{L}_i \mathbf{R} \mathbf{L}_i^\top$, we can derive expression for $\mathbf{L}_i$ as a function of $\mathbf{P}_{i+1}^-$:

$$\mathbf{L}_i \mathbf{R} = \mathbf{P}_{i+1} \mathbf{H}^\top \quad (39)$$

$$\mathbf{L}_i \mathbf{R} \mathbf{L}_i^\top = \mathbf{P}_{i+1} \mathbf{H}^\top \mathbf{L}_i^\top \quad (40)$$

$$\mathbf{P}_{i+1} = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- (\mathbf{I} - \mathbf{L}_i \mathbf{H})^\top + \mathbf{P}_{i+1} \mathbf{H}^\top \mathbf{L}_i^\top \quad (41)$$

$$\mathbf{P}_{i+1} (\mathbf{I} - \mathbf{H}^\top \mathbf{L}_i^\top) = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- (\mathbf{I} - \mathbf{L}_i \mathbf{H})^\top \quad (42)$$

Assuming that $\det(\mathbf{I} - \mathbf{L}_i \mathbf{H})^\top \neq 0$, we can multiply on the right by $(\mathbf{I} - \mathbf{L}_i \mathbf{H})^{-\top}$:

$$\mathbf{P}_{i+1} = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- \quad (43)$$

$$\mathbf{P}_{i+1} = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- \quad (44)$$

$$\mathbf{P}_{i+1} \mathbf{H}^\top \mathbf{R}^{-1} = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- \mathbf{H}^\top \mathbf{R}^{-1} \quad (45)$$

$$\mathbf{L}_i = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- \mathbf{H}^\top \mathbf{R}^{-1} \quad (46)$$

$$\mathbf{L}_i \mathbf{R} = (\mathbf{I} - \mathbf{L}_i \mathbf{H}) \mathbf{P}_{i+1}^- \mathbf{H}^\top \quad (47)$$

$$\mathbf{L}_i \mathbf{R} + \mathbf{L}_i \mathbf{H} \mathbf{P}_{i+1}^- \mathbf{H}^\top = \mathbf{P}_{i+1}^- \mathbf{H}^\top \quad (48)$$

$$\mathbf{L}_i (\mathbf{R} + \mathbf{H} \mathbf{P}_{i+1}^- \mathbf{H}^\top) = \mathbf{P}_{i+1}^- \mathbf{H}^\top \quad (49)$$

$$\mathbf{L}_i = \mathbf{P}_{i+1}^- \mathbf{H}^\top (\mathbf{R} + \mathbf{H} \mathbf{P}_{i+1}^- \mathbf{H}^\top)^{-1}. \quad \square \quad (50)$$